



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

پروژه درس برنامه ریزی حمل و نقل و لجستیک
استاد: دکتر صادقی

اعضای گروه:

پانید اطاقی

پاییز 1404

مقدمه

توضیحات پروژه

فرض کنید شما در حال بررسی یک بازار تاکسی اینترنتی هستید و قصد دارید که بررسی کنید که سیستم قیمت گذاری شما چگونه عمل کرده است. بدین منظور یک مجموعه داده واقعی از یک اپلیکیشن تاکسی آنلاین در اختیار شما قرار گرفته است که شامل تعدادی درخواست سفر از سوی مسافران و دارای 11 ستون می باشد که به ترتیب نشان دهنده موارد زیر است:

مشخصات داده ها

price_check_time: 1. زمان درخواست محاسبه قیمت توسط مسافر

passenger: 2. شماره شناسایی مسافر

origin: 3. شماره شناسایی منطقه مبدا سفر

destination: 4. شماره شناسایی منطقه مقصد سفر

price: 5. قیمت پیشنهادی سفر (قبل از اعمال تخفیف)

subsidy: 6. میزان تخفیف

distance: 7. مسافت سفر (بر حسب متر)

expected_duration: 8. مدت زمان تخمینی سفر (بر حسب دقیقه)

req_time: 9. زمان ارسال درخواست سفر

driver: 10. شماره شناسایی راننده ای که سفر را قبول کرده است

status: 11. وضعیت درخواست سفر

1: -سفر انجام شده است

2: -سفر توسط مسافر لغو شده است

3: -سفر توسط راننده لغو شده است

4: -راننده سفر را قبول نکرده است

blank: درخواستی ثبت نشده است این بدان معناست که مسافر درخواست محاسبه قیمت داشته است اما در نهایت درخواست

سفری را ثبت نکرده است


بخش 1: تحلیل داده ها

در این بخش، مطابق صورت مسئله، ابتدا داده ها به صورت کلی بررسی و پیش پردازش شدند (حذف رکوردهای نامعتبر، مدیریت مقادیر گم شده و حذف داده های پرت با روش IQR). سپس تحلیل های خواسته شده شامل ماتریس های OD، تقاضای برآورده نشده، تحلیل زمانی و تحلیل کنسلی انجام گردید.

1. تحلیل ماتریس های OD


هدف این بخش استخراج الگوی تقاضا بین نواحی مختلف است. ماتریس تقاضا تعداد همه درخواست ها را نشان میدهد و ماتریس سفرهای انجام شده تنها شامل $status=1$ است. مقایسه این دو ماتریس مشخص میکند کدام OD ها علاوه بر تقاضای بالا، نرخ انجام بالاتری هم دارند.

برداشت تحلیلی: ماتریس تقاضای سفر را به صورت یک نمودار Heatmap نمایش داده شده است. این ماتریس نشان دهنده تعداد درخواست سفر بین هر جفت مبدا و مقصد ثبت شده است و حتی سفر هایی که اتفاق نیوفتاده اند را در نظر می گیرد. این نمودار نشان می دهد که تقاضا به صورت یکنواخت توزیع نشده است و اکثر سفر ها برای برخی مناطق است مانند سفر از مبدا 2 به مقصد 0 که بیشترین تعداد سفر در آن رخ می دهد. برخی قسمت ها که به بنفش نشان داده شده اند هیچ تقاضای سفری ندارند و این موضوع نشان می دهد که کانون های اصلی سفر در شهر وجود دارد که شامل مراکز پتراکم مانند مراکز تجاری، اداری و یا مسکونی باشد. سیستم حمل و نقل در این نواحی اهمیت فراوانی دارد و به خاطر تقاضای بیشتر فشار بیشتری به آن وارد می شود که نیازمند به مدیریت دقیق تر و برنامه ریزی بهتری است. OD های پرتکرار عمدتاً در بلوک مناطق 0 تا 2 متمرکز هستند و همچنین زیرمجموعه ای از درخواست ها در نواحی 3 و 4 جریان دارد. کاهش مقدار سلول ها از ماتریس تقاضا به ماتریس انجام شده، بیانگر سهم لغو یا عدم تحقق تقاضا در آن OD است.



شکل ۱ — ماتریس تقاضای OD همه درخواست ها


در نمودار بعدی ماتریس سفرهای انجام شده را رسم شده است. با مقایسه این نمودار با نمودار قبلی می توان فهمید که تقاضا در برخی مسیر ها به سفر انجام شده تبدیل نشده اند. این اختلاف ضعف سیستم حمل و نقل در پاسخگویی به تقاضا را نشان می دهد. این نواحی می توانند نقاط بحرانی یا گلوگاه های سیستم ما باشند.



شکل ۲ — ماتریس سفرهای انجام شده (status=1) OD

2. بررسی درصد تقاضای برآورده نشده

- چند درصد از تقاضاها بدون راننده باقی مانده اند **status=4**؟ و این درصد در ساعات مختلف روز چه تغییری دارد؟
- در این بخش تمرکز بر روی تقاضا هایی است که با وضعیت چهار رو به رو شده اند. این درخواست ها به خاطر نبود راننده پاسخ داده نشده اند. با تحلیل نتایج نمودار متوجه می شویم که در ساعات خاصی از روز تقاضای برآورده نشده افزایش می یابد که معمولا همراه با دوره های اوج تقاضای همزمان است. در این زمان تعداد زیادی تقاضا با سرعت بیشتری از رانندگان به وجود می آید که این مشکل را به وجود می آورد. علت اصلی این اتفاق عدم تعادل بین تقاضا و عرضه در آن زمان است. به طورمثال نمودار نشان می دهد که در ساعت 5 و 2 درصد تقاضا های برآورده نشده بسیار بیشتر از بقیه ساعت ها است.



- کدام جفت مبدا-مقصد بیشترین درصد تقاضا را داشته‌اند؟

در ادامه به تحلیل جفت‌های مبدا-مقصد می‌پردازیم. جدول زیر نشان می‌دهد که برخی مسیرها سهم بیشتری از کل تقاضا را به خود اختصاص داده‌اند. این مسیرها معمولاً همان مسیرهایی هستند که در ماتریس OD نیز رنگ پررنگ تری داشتند و تعداد تقاضای بیشتری به خود اختصاص می‌دهند. تمرکز تقاضا به این مسیرها می‌تواند از یک نظر مفید باشد زیرا به برنامه ریزی درست می‌تواند باعث افزایش بهره‌وری و سودآوری ما شود و همچنین اگر به خوبی کنترل نشود می‌تواند باعث نارضایتی مسافران شود. این نواحی اهمیت دارای اهمیت فراوانی هستند و باید به خوبی برای آن‌ها برنامه ریزی کرد. طبق جدول زیر مسیری که از مبدا 2 به مقصد 0 می‌رود بیشترین تقاضا و اهمیت را دارد.

	origin	destination	demand_share_percent
0	2	0	16.91
1	1	1	15.06
2	1	0	14.13
3	2	1	13.00
4	3	3	12.13

- برای کدام مبدا _ مقصد ها قیمت به‌ازای هر کیلومتر بیشترین نوسان را دارد؟

در جدول بعدی نوسان قیمت به ازای هر کیلومتر با توجه به مسیر متفاوت نمایش داده شده است. این جدول نشان می دهد که برخی مسیر ها دارای نوسان خیلی بیشتری نسبت به بقیه مسیر ها دارند. این نوسان ها نشان دهنده تغییرات شدید ترافیک، زمان های مخلف روز و یا قیمت گذاری متفاوت با توجه به زمان و ترافیک است. این نوسان برای مسافران و رانندگان ناخوشایند است و می تواند نرخ کنسلی و یا عدم پذیرش را افزایش دهد.

		mean	std	count
origin	destination			
0	2	18333.778500	6864.720419	303
4	4	22161.373717	6603.011056	119
3	3	16800.771437	6015.266765	1695
1	0	22628.194398	5647.243404	1974
2	1	18484.582466	5616.039266	1817
0	0	17271.728404	5579.438134	795
1	2	16870.629201	5335.905957	870
	1	17623.600340	4750.147073	2105
4	3	14872.464987	4656.589062	317
3	4	13695.862768	4524.454502	413

- در ساعات های پیک (۸-۶ صبح و ۱۹-۱۶ عصر) متوسط نسبت تخفیف به قیمت سفر چند درصد است؟ این نسبت را با ساعت های غیر پیک مقایسه کنید.


نسبت تخفیف به قیمت سفر در ساعات پیک نشان می دهد که در بازه های ۶ تا ۸ صبح و ۱۶ تا ۱۹ عصر، این نسبت به طور معناداری با ساعات غیرپیک تفاوت دارد. معمولاً در ساعات پیک، یا میزان تخفیف کاهش می یابد تا از شلوغی بیش از حد جلوگیری شود، یا تخفیف ها به صورت هدفمند اعمال می شوند تا تقاضا به مسیرها یا زمان های خاصی هدایت شود. مقایسه این نسبت با ساعات غیرپیک نشان می دهد که سیاست های قیمتی نقش مهمی در تنظیم رفتار کاربران دارند.

Peak hours discount/price ratio: 15.68%
Off-peak discount/price ratio: 15.05%

3. تحلیل زمانی

- نمودار توزیع تعداد درخواست ها در ساعات مختلف شبانه روز را رسم کنید. در چه ساعاتی بیشترین و کمترین درخواست سفر ثبت می شود؟


نمودار توزیع تعداد درخواست ها در ساعات مختلف شبانه روز نشان می دهد که تعداد درخواست ها در ساعات اولیه صبح و ساعات پایانی شب کمتر است. همچنین بیشترین حجم درخواست ها در ساعات رفت و آمد روزانه ثبت می شود. این الگو مانند الگوی فعالیت های شغلی و اجتماعی شهر است و تأیید می کند که تقاضای سفر به شدت تابع زمان است. بیشترین تقاضا در ساعت 18 با مقدار 1174 رخ می دهد که ساعت تعطیلی شرکت ها نیز است و همچنین کم ترین تقاضا در ساعت 5 صبح رخ می دهد که مقدار آن 31 است.



- بررسی کنید سطح و نوسانات قیمت در ساعات مختلف روز چگونه می باشد؟

برای تحلیل قیمت، میانگین و انحراف معیار `price_after_discount` در هر ساعت محاسبه شد. خطای استاندارد در اینجا نمایش داده نشده و نمودار به صورت $\text{mean} \pm \text{std}$ رسم شده است تا هم سطح قیمت و هم پراکندگی آن قابل مشاهده باشد. قیمت میانگین در ساعات مختلف تغییر میکند و در برخی ساعات پراکندگی `std` بالاتر است؛ این موضوع میتواند نشاندهنده اثر قیمتگذاری پویا و تغییرات تقاضا در طول روز باشد. تحلیل سطح و نوسانات قیمت در ساعات مختلف روز نشان می دهد که قیمت ها در ساعات پیک بالاتر هستند و نوسانات بیشتری دارند. این موضوع نشان دهنده ی قیمت گذاری پویا است که هدف آن مدیریت تقاضا و تشویق رانندگان به فعالیت در زمان های پرتراфик است. همچنین در ساعات کم تقاضا، قیمت ها پایدارتر و قابل پیش بینی تر هستند. طبق نودار زیر هم قیمت هر سفر در ساعات اولیه روز بسیار بیشتر از اواسط روز است در صورتی که در آن ساعات طبق نمودار های قبلی

تقاضا کم است. این نشان می دهد سفر های آن زمان با وجود کمتر بودن قیمت بیشتری را به خود اختصاص می دهند تا راننده تمایل به قبول آن داشته باشد. بعد از ساعت 5 صبح قیمت هر سفر یک دفعه کاهش پیدا می کند اما تقاضای آن بالا می رود که نوع دیگری از جذابیت را برای راننده داشته باشد.




4. تحلیل کنسلی سفر

- یک نمودار رسم کنید و تاثیر مسافت، قیمت و مدت زمان تخمینی سفر بر کنسلی توسط مسافر را نشان دهید (از نمودار 3 بعدی استفاده نکنید).

نمودار زیر رابطه ی بین مسافت، قیمت و مدت زمان تخمینی سفر با کنسلی توسط مسافر را نشان می دهد. با توجه به این نمودار می توان فهمید که با افزایش هر یک از این متغیرها، احتمال کنسلی افزایش پیدا می کند. به ویژه سفرهای طولانی با قیمت بالا و زمان تخمینی زیاد بیشترین نرخ کنسلی را دارند، که نشان دهنده حساسیت بالای مسافران به هزینه و زمان است.


طبق صورت مسئله، باید بدون استفاده از نمودار سه بعدی، اثر سه عامل مسافت، قیمت و مدت زمان تخمینی بر نرخ کنسلی بررسی شود. برای ارائه یک نمودار برای هر سمت (مسافر/راننده)، هر عامل به ۱۰ دهک Decile تقسیم شد و نرخ کنسلی در هر دهک محاسبه گردید؛ سپس هر سه منحنی در یک نمودار رسم شدند.

تفسیر محور افقی: دهک ۱ یعنی کمترین مقدار آن عامل و دهک ۱۰ یعنی بیشترین مقدار.



• تحلیل بالا را از سمت راننده انجام دهید.

این نمودار از دید راننده هم رسم شده است. طبق نمودار رانندگان می خواهند سفرهایی با مسافت کوتاه تر، قیمت مناسب تر و زمان تخمینی کمتر است را بپذیرند. سفرهایی که از نظر راننده بازده اقتصادی یا زمانی مطلوبی ندارند، بیشتر با کنسلی از سمت راننده مواجه می شوند. همچنین این نمودار نشان می دهد که مسافت سفر نقش پررنگ تری در تصمیم به کنسلی دارد. رانندگان تمایل کمتری به پذیرش سفرهای بسیار کوتاه یا بسیار طولانی دارند، به ویژه زمانی که قیمت به ازای هر کیلومتر جذاب نباشد. همچنین افزایش زمان تخمینی سفر، به خصوص در ساعات پرتراфик، احتمال کنسلی توسط راننده را افزایش می دهد. این موضوع نشان می دهد که رانندگان بیش از هر چیز به بهره وری زمانی و درآمد نسبی توجه دارند.



همچنین تحلیل این دو نمودار نشان می‌دهد که رفتار کنسلی مسافر و راننده از منطق‌های متفاوتی پیروی می‌کند. مسافر به دنبال کاهش هزینه و زمان است، در حالی که راننده به سودآوری و مدیریت زمان خود توجه دارد. این تفاوت رفتاری اگر در طراحی الگوریتم‌های قیمت‌گذاری و تخصیص سفر در نظر گرفته نشود، می‌تواند منجر به افزایش نارضایتی هر دو طرف و کاهش کارایی کل سیستم شود. اگر یکی از منحنیها با افزایش دهک روند صعودی داشته باشد، آن عامل با افزایش مقدارش با افزایش احتمال کنسلی همراه است. اگر روند نزولی باشد، با کاهش احتمال کنسلی همراه است. همچنین اگر منحنیها تقریباً تخت باشند، اثر آن عامل در این داده‌ها ضعیف یا غیرخطی است.

بخش 2: تحلیل رفتار مسافرین و رانندگان

به کمک کتابخانه‌های FITTER و scipy.stats به سوالات زیر پاسخ داده شد. برای پاسخ به سوالات آماری از تست fisher و t استفاده شد. (در سطح اطمینان 95٪)

پیش پردازش داده ها و برازش توزیع ها (خلاصه)

ابتدا تنها درخواست های واقعی سفر (دارای req_time غیرتهی) نگه داشته شد. سپس رکوردهای نامعتبر (قیمت، مسافت یا زمان تخمینی نامعتبر یا منفی) حذف شدند. در نهایت، داده های پرت با استفاده از روش IQR برای متغیرهای کلیدی حذف گردیدند. نتیجه این مراحل، دیتاست نهایی پاکسازیشدهای است که مبنای تمام تحلیلهای آماری این بخش قرار گرفته است. برای بررسی شکل توزیع متغیرهای پیوسته، چند توزیع رایج شامل نرمال، لاگنرمال، گاما و نمایی بر روی داده ها برازش داده شد و با استفاده از معیار AIC با یکدیگر مقایسه شدند. نتایج نشان داد:

- برای متغیر قیمت پس از تخفیف price_after_discount توزیع گاما کمترین مقدار AIC را دارد.

- برای متغیر مسافت سفر distance_km نیز توزیع گاما بهترین برازش را ارائه میدهد.

این موضوع بیانگر آن است که هر دو متغیر دارای توزیعی چوله به راست هستند و فرض نرمال بودن آنها چندان مناسب نیست؛ به همین دلیل استفاده از آزمونهای مقاومتر مانند Welch t-test توصیه پذیر است.

1. آیا قیمت پیشنهادی سفر تأثیر معناداری بر لغو سفر توسط مسافر داشته است؟

فرض صفر (H_0): میانگین قیمت پیشنهادی برای سفرهایی که توسط مسافر لغو شده اند با سفرهایی که لغو نشده اند برابر است.

فرض مقابل (H_1): بین این دو میانگین تفاوت معنادار وجود دارد.

برای آزمون این فرض، از آزمون Welch t-test استفاده شد. نتایج آزمون:

- مقدار $p\text{-value} \approx 0.93$
- میانگین قیمت در سفرهای لغوشده توسط مسافر $\approx 50,431$
- میانگین قیمت در سفرهای لغونشده $\approx 50,457$

از آنجا که مقدار $p\text{-value}$ بسیار بزرگتر از 0.05 است، فرض صفر رد نمیشود.

در این داده ها، قیمت پیشنهادی سفر تأثیر معناداری بر لغو سفر توسط مسافر نداشته است. به بیان دیگر، تفاوت قیمت بین سفرهای لغوشده و لغوننشده از نظر آماری معنادار نیست.

2. آیا مسافت سفر تأثیر معناداری بر لغو سفر توسط راننده داشته است؟

فرض صفر (H_0): میانگین مسافت سفر در لغوهای انجام شده توسط راننده با سایر سفرها برابر است.

فرض مقابل (H_1): بین این دو میانگین تفاوت معنادار وجود دارد.

برای آزمون این فرض نیز از Welch t-test استفاده شد.

نتایج آزمون:

- مقدار $p\text{-value} \approx 0.72$
- میانگین مسافت در لغوهای راننده ≈ 3.21 کیلومتر
- میانگین مسافت در سفرهای بدون لغو راننده ≈ 3.19 کیلومتر

مقدار $p\text{-value}$ بزرگتر از 0.05 است؛ بنابراین فرض صفر رد نمیشود. بر اساس این داده ها، مسافت سفر تأثیر معناداری بر لغو سفر توسط راننده نداشته است.

3. آیا درخواست‌های با تخفیف ($\text{subsidy} > 0$) نسبت به درخواست‌های بدون تخفیف، احتمال بیشتری برای

پذیرش توسط مسافر دارند؟

در این سؤال، پذیرش مسافر به صورت ثبت درخواست واقعی پس از مشاهده قیمت `req_time` غیرتهی پس از `price_check_time` در نظر گرفته شد.

فرض صفر (H_0): وجود تخفیف $\text{subsidy} > 0$ اثری بر احتمال پذیرش سفر توسط مسافر ندارد.

فرض مقابل (H_1): وجود تخفیف احتمال پذیرش را تغییر میدهد.

برای بررسی این موضوع، از آزمون Fisher Exact Test روی یک جدول دو×دو استفاده شد.

نتایج آزمون Fisher:

- مقدار $p\text{-value} \approx 0.84$
- Odds Ratio ≈ 0.99
- نرخ پذیرش با تخفیف $\approx 62.5\%$
- نرخ پذیرش بدون تخفیف $\approx 62.7\%$

مقدار $p\text{-value}$ بزرگتر از 0.05 است؛ بنابراین فرض صفر رد نمی شود. در این دیتاست، وجود تخفیف تأثیر معناداری بر افزایش احتمال پذیرش سفر توسط مسافر نداشته است. نرخ پذیرش در درخواست های دارای تخفیف و بدون تخفیف تقریباً یکسان است.

نتایج تحلیل های آماری این بخش نشان می دهد که:

- قیمت پیشنهادی سفر تأثیر معناداری بر لغو سفر توسط مسافر نداشته است.
 - مسافت سفر تأثیر معناداری بر لغو سفر توسط راننده نداشته است.
 - وجود تخفیف $subsidy > 0$ به طور معنادار باعث افزایش احتمال پذیرش سفر توسط مسافر نشده است.
- این نتایج نشان می دهد که تصمیم های لغو یا پذیرش در این داده ها احتمالاً تحت تأثیر عوامل دیگری غیر از قیمت، مسافت و تخفیف قرار دارند.

بخش 3: پیش بینی رفتار

در این بخش مطابق صورت مسئله، ابتدا با یک مدل رگرسیون خطی قیمت سفر پیش بینی می شود و سپس با رگرسیون لجستیک پیش بینی میکنیم آیا برای درخواست سفر «راننده پیدا میشود» یا خیر. ($status \neq 4$) پیش پردازش داده ها (فیلتر اعتبار، حذف داده های پرت با IQR و مهندسی ویژگی ها) مشابه مراحل قبلی انجام شده است.

1. رگرسیون خطی برای پیش بینی قیمت سفر

مدل LinearRegression با Pipeline شامل StandardScaler برای ویژگی های عددی و OneHotEncoder برای ویژگی های دسته ای، ورودی ها:

- عددی: hour، distance_km، expected_duration، subsidy
- دسته ای: origin، destination

1.1. معیارهای ارزیابی مدل

معیارهای ارزیابی مدل رگرسیون:

MAE (Mean Absolute Error)

RMSE (Root Mean Squared Error)

MAPE (Mean Absolute Percentage Error)

R^2 Score

[Linear Regression Metrics]

MAE=6824, RMSE=8835, MAPE=11.54%, $R^2=0.594$

تفسیر R^2 : حدود 0.59 یعنی مدل حدود 59٪ تغییرات قیمت را توضیح می دهد؛ بنابراین مدل متوسط رو به خوب است ولی هنوز بخشی از تغییرات قیمت با ویژگی های در دسترس قابل توضیح نیست. همچنین از باقی معیارها مشخص است که مدل خطا دارد.

2.1. مقایسه یک رکورد واقعی vs پیش بینی

نمونه از داده های تست: (index=17239)

Sample record index: 17239

Real price=50000, Predicted=59891, Abs error=9891, Percent error=19.8%


Is sample error <= MAE? False

- قیمت واقعی 50000
- قیمت پیش‌بینی شده 59891
- اختلاف مطلق 9891
- اختلاف درصدی 19.8%
- مقایسه با MAE: کمتر قابل قبول ($> \text{MAE}$)

یعنی اختلاف نسبت به میانگین خطای مدل قابل قبول نیست.

3.1. مهم‌ترین ویژگی‌ها در پیش‌بینی قیمت (Coefficients)

بر اساس قدر مطلق ضرایب مدل، مهم‌ترین عوامل در این مدل خطی معمولاً مسافت و مدت زمان تخمینی هستند و سپس یارانه/تخفیف (subsidy). شکل زیر بزرگ‌ترین ضرایب را نشان می‌دهد.




شکل ۱ — بزرگ‌ترین ضرایب مدل رگرسیون خطی (Top |coefficients|)

4.1. بررسی عملکرد مدل در سفرهای با مسافت زیاد (Residual vs Distance)


برای بررسی اینکه آیا مدل روی سفرهای طولانی رفتار متفاوتی دارد یا خیر، نمودار باقی مانده‌ها در برابر مسافت رسم شد. اگر پراکندگی خطا در مسافت‌های بالا بیشتر شود یا میانگین خطا در بین‌های مسافت به سمت مثبت/منفی میل کند، می‌توان نتیجه گرفت مدل روی سفرهای طولانی‌تر نامطمئن‌تر یا دارای سوگیری است. بررسی نمودار residual در برابر مسافت نشان می‌دهد که اگرچه با افزایش مسافت، پراکندگی خطای مدل افزایش می‌یابد، اما میانگین خطا حول صفر باقی مانده و الگوی سیستماتیکی از

بیش برآورد یا کم برآورد قیمت در سفرهای طولانی مشاهده نمی‌شود. بنابراین مدل نسبت به مسافت‌های زیاد سوگیری معناداری ندارد، هرچند عدم قطعیت پیش‌بینی در این بازه‌ها بیشتر است. نتایج نمودارها با دو روش محاسبه مختلف در ادامه قرار داده شده است.

روش اول:




شکل ۲ Residual — در برابر مسافت




شکل ۳ — میانگین Residual در بازه‌های مسافت (qcut)

روش دوم:



شکل ۲ Residual — در برابر مسافت



شکل ۳ — میانگین Residual در بازه‌های مسافت (qcut)

2. رگرسیون لجستیک برای پیش‌بینی پذیرش راننده

هدف: $accepted_by_driver = 1$ اگر برای درخواست راننده پیدا شده باشد $status \neq 4$ و 0 در غیر این صورت.

ویژگی‌ها مطابق ساختار پیشنهادی:


- عددی: `hour`, `distance_km`, `subsidy` با `StandardScaler`
- دست‌های: `origin` (با `OneHotEncoder`)

برای کاهش اثر عدم توازن کلاس ها از `class_weight='balanced'` استفاده شد.

1.2. معیارهای ارزیابی مدل لجستیک

ROC-AUC=0.511, F1=0.724, Recall=0.574, Precision=0.980, Accuracy=0.571

تفسیر: ROC-AUC نزدیک 0.5 نشان میدهد قدرت تفکیک مدل بالا نیست (تقریباً نزدیک به حد تصادفی). با این حال Precision بالا یعنی وقتی مدل «راننده پیدا میشود» را پیشبینی می کند اغلب درست است، اما Recall متوسط نشان می دهد بسیاری از موارد «راننده پیدا میشود» را هم از دست میدهد.



شکل ۴ — ماتریس درهم ریختگی (Confusion Matrix)

2.2. تحلیل ضرایب: اثر تخفیف و مسافت

در رگرسیون لجستیک علامت ضریب نشاندهنده جهت اثر است (پس از استانداردسازی). $Odds Ratio = \exp(coef)$ نیز تفسیر مستقیم تری از تغییر شانس ارائه میکند.

• `subsidy: coef=0.016` → $OR=1.016$ اثر افزایشی بر احتمال یافتن راننده

• `distance_km: coef=-0.029` → $OR=0.972$ اثر کاهشی بر احتمال یافتن راننده

نتیجه گیری: طبق ضرایب این مدل، تخفیف اثر مثبت (هرچند کوچک) دارد و افزایش مسافت اثر منفی دارد؛ یعنی سفرهای طولانی تر معمولاً سخت تر راننده پیدا می کنند.